modéliser les données de la recherche avec le CIDOC CRM

📡
thomas.bottini@cnrs.fr

Institut de Recherche en Musicologie UMR 8223

[la question qui nous réunit]

Comment faire tenir les données de la recherche dans le temps ?

- 📜 Comment s'assurer qu'on puisse toujours les voir, les comprendre, les modifier ?
- 🔬 Comment capter et transmettre les « traditions interprétatives » sans les amoindrir ?
- 🎓 Comment fonctionner avec des moyens 👥/💻/💶 limités ?
- 🌐 Comment favoriser les liens avec d'autres systèmes d'information ?
- 💾 À quels 🧺 confier ses 🥚 ?

modéliser sous contraintes de ressources

- La modélisation des données nécessite une réflexion conjointe entre chercheurs et ingénieurs.
  - Ce dialogue a une fonction maïeutique, il doit confronter le chercheur ou la chercheuse à des cas limites pour l'amener à mieux comprendre ses objets d'étude.
  - Le travail d'explicitation, de modélisation, des données a une fonction heuristique : aider à révéler la structure interne des sources et des phénomènes étudiés.
- Or, souvent, la modélisation est perçue comme une étape purement technique par le client et est renvoyée à la compétence du prestataire.
- Les ressources d'ingénierie sont trop maigres, ce niveau dialogue est rare.

De plus, l'époque est au FAIR et au LOD⭐⭐⭐⭐⭐ (des notions relativement spécifiques à notre contexte professionnel). L'ouverture des données de la recherche, leur interopérabilité et leur mise en relation avec des sources de données tierces nécessitent une réflexion technique, méthodologique et scientifique très en amont dans le projet. Après, c'est souvent trop tard.

ce qu'on cherche à palier avec les consortiums

- La FAIRisation des données suppose une dynamique informationnelle intellectuelle et technique entre les projets de BDD.
- Pour la bâtir, un réseau d'acteurs et d'actrices est nécessaire, mais :
  - Il faut une complémentarité recherche🔬/ingénierie⚙️/SIB📚 car ces connaissances sont très abstraites et difficiles à saisir.
  - Les chercheurs et chercheuses devant piloter de tels projet manquent d'informations claires sur les conséquences scientifiques et méthodologiques des technologies disponibles pour modéliser les informations scientifiques.
  - Les profils techniques sont recrutés sur des contrats courts.
  - Les prestataires n'ont pas d'intérêt à s'inscrire dans les réseaux HN.
- Conséquemment, les connaissances d'ingénierie spécifiques à la modélisation des données de la discipline sont peu capitalisées ; chaque nouveau développement peine à bénéficier de l'expérience méthodologique et conceptuelle acquise informellement au fil des projets passés.

ENCODER

MODÉLISER

SAISIR

EXPLORER

PÉRENISER

ENCODER

quelques problèmes potentiels avec les sgbdr

- Un modèle relationnel est souvent conçu ici & maintenant : il formalise et matérialise une tâche d'analyse d'une pratique de recherche spécifique. Le risque est de « réinventer » la roue, sur le plan conceptuel, à chaque réitération de cette démarche d'analyse. Pourtant, il existe des similarités entre les pratiques de recherche en SHS liées aux données numériques.
- La sémantique d'un modèle relationnel ne peut être techniquement partagée, ce qui peut poser des problèmes de lecture et de compréhension plus tard.
- L'accès aux données par un système tiers peut être malaisé. Souvent, on doit développer une API, qui est déterminée par le cahier des charges du projet, alors qu'on sait qu'on ne peut anticiper tous les usages futurs des données (c'est l'idée même des LOD). C'est aussi un point de tension dans le dialogue avec le prestataire : tout changement apporté au modèle vu comme minime par le client peut avoir d'importantes conséquences sur le développement.
- Tout ceci amène à parler d'architectures « en silo ».

pervasivité des sgbdr

- Le panorama technologiques des outils permettant de construire rapidement des applications Web de saisie collaborative de données est dominé par les systèmes reposant sur les SGBDR :
  - CMS & assimilés (Wagtail, Drupal, Omeka, Heurist)
  - systèmes « no-code »
  - frameworks full-stack qui existent dans tous les langages de programmation
- Les SGBDR, et avec eux, la méthode Merise et le SQL, sont enseignés partout, à tous les niveaux. Les compétences d'ingénierie sont donc très répandues.

le web sémantique:

- Promesse d'une base de données à l'échelle du Web. Le Web initial (Tim Berners Lee, 1991) était un Web de documents liés (hypertexte), le Web sémantique est un Web de données liées, chacune étant identifiée par une URL.
- Toute information s'exprime sous la forme d'un triplet sujet/prédicat/objet dans un langage de description qui est le RDF.

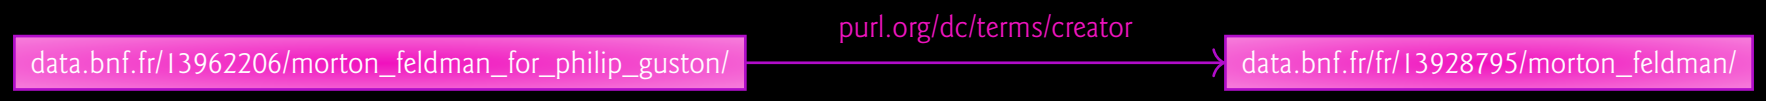

- Connectés, ces triplets RDF forment un graphe. Idée de modèle ouvert.
- Chaque prédicat est également identifié par une URL. Cela permet de toujours savoir de quoi on parle quand on dit, par exemple : « Titre ».
- Tout graph RDF est interrogeable en SPARQL (+ standardisé que SQL).
- C'est le milieu technique idéal pour nos préoccupations : LOD, FAIR, etc.

MODÉLISER

une ontologie : quoi, pourquoi ?

- Formalisation d'un modèle conceptuel pour un domaine donné, contenant des classes et des propriétés.
- Utiliser les classes et les propriétés d'une ontologie confère ainsi une sémantique partagée aux données.
- Permet de capitaliser des connaissances de modélisation d'un projet à l'autre.
- Le Web sémantique s'accompagne de standards utiles pour nos métiers : SKOS pour les thésaurus, DCMI pour les métadonnées basiques, DOREMUS pour la musique écrite/éditée/jouée/diffusée, LRMOO pour l'information bibliographique, PROV-O pour la provenance de l'information, et bien sûr le CIDOC CRM.
- Bien des projets de recherche alliant informatique et SHS se donnent pour mission de produire une nouvelle ontologie pour couvrir un besoin spécifique. Nous défendons la thèse opposée : tenter de tout modéliser avec le CIDOC CRM.

motivations sur le plan de l'ingénierie logicielle

- Le recours à un standard pour représenter les données permet mieux structurer le développement informatique :
  - Le modèle est partagé par
  - Les standards métier nous le montrent (IIIF, MEI, TEI…).

laquelle ? le cidoc crm !

- Ontologie qui documente le patrimoine matériel et immatériel ainsi que les processus de production de connaissances à son propos (sources, connaissances, faits sociaux, concepts, objets matériels, idées dénotées ou connotées, contexte de production des connaissances, etc.).
- Communauté large et établie. Venant du monde des musées, elle est désormais utilisée dans tous les domaines des HN
- Ontologie centrée événement.
- Informations bibliographiques avec LRMoo (œuvres, expressions, manifestation, item).

hiérarchie des classes du cidoc crm

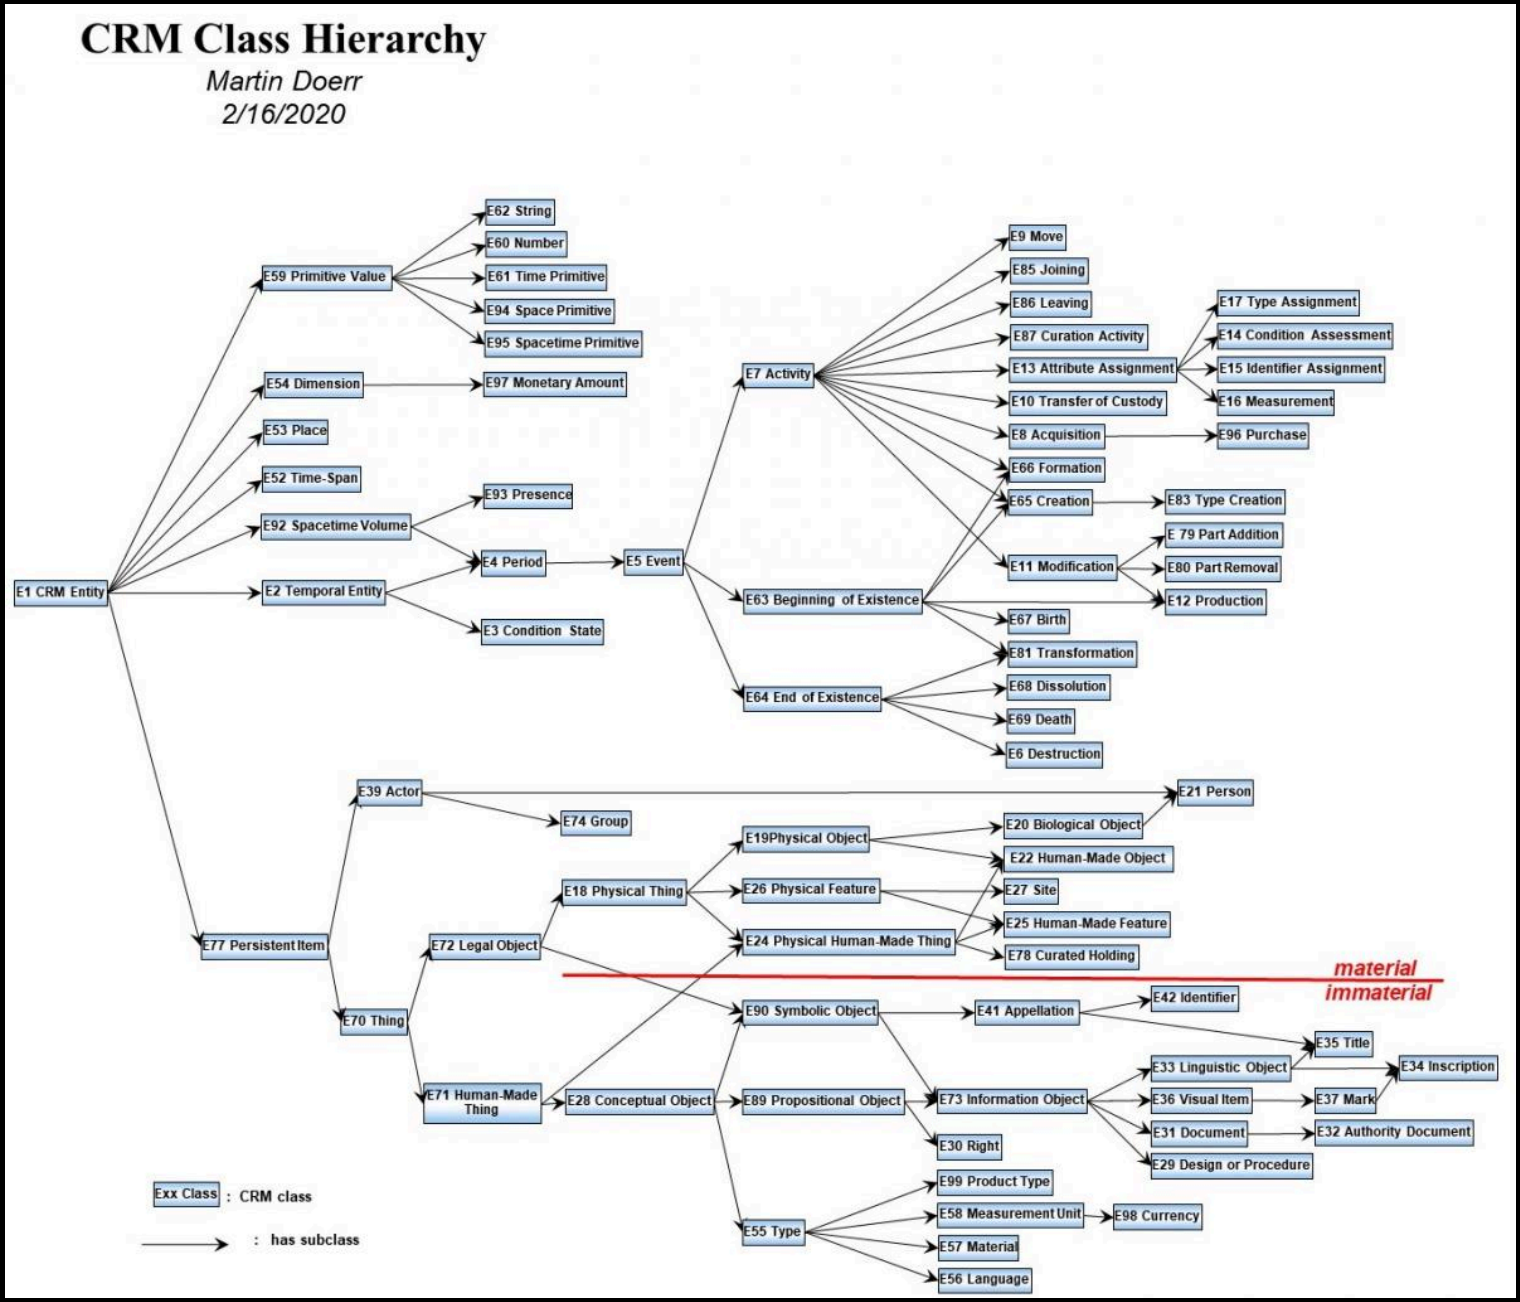

opérations critiques & patterns de base

- Nommer
- Identifier
- Dater
- Contextualiser
- Structurer
- Indexer
- Annoter

SAISIR

ça se complique

- Sur le plan conceptuel, le CRM est expressif (il aide à ne pas réduire ni trahir les productions analytiques des chercheurs et des chercheuses), est maintenu par une communauté forte, mais est complexe à comprendre et à mettre en œuvre :
  - Il existe parfois plusieurs manières de modéliser une situation avec les classes de base.
  - C'est une ontologie extrêmement abstraite et générique.
- Sur le plan ergonomique :
  - Un graphe ouvert est plus difficile à éditer que des données relationnelles (données tabulaires s'éditant naturellement avec des formulaires contraints).
  - Les patterns fondamentaux du CRM (pour nommer, typer, dater, annoter, contextualiser...) induisent beaucoup de sous-entités. Nous sommes loins du modèle ligne/colonne/cellule.
  - Rien ne peut battre un tableur pour l'édition d'items similaires rassemblés dans une collection.

du relationnel au rdf

- Mapping
- Le modèle relationnel doit être créé pour répondre aux attendus ergonomiques du projet. Sa structure doit permettre de générer des données CIDOC CRM par la suite, mais il n'est qu'un modèle de saisie. Il représente la manière dont un collectif se saisit du CRM dans un contexte précis (classes et propriétés utilisées + idiomes de modélisation.
- Du code doit être écrit pour récupérer les données via l'API offerte par le système et les convertir en données RDF modélisées avec le CIDOC CRM (des couples efficace pour ce genre de tâches : python/rdflib, deno/https://rdf.js.org/)

le pipeline sherlock

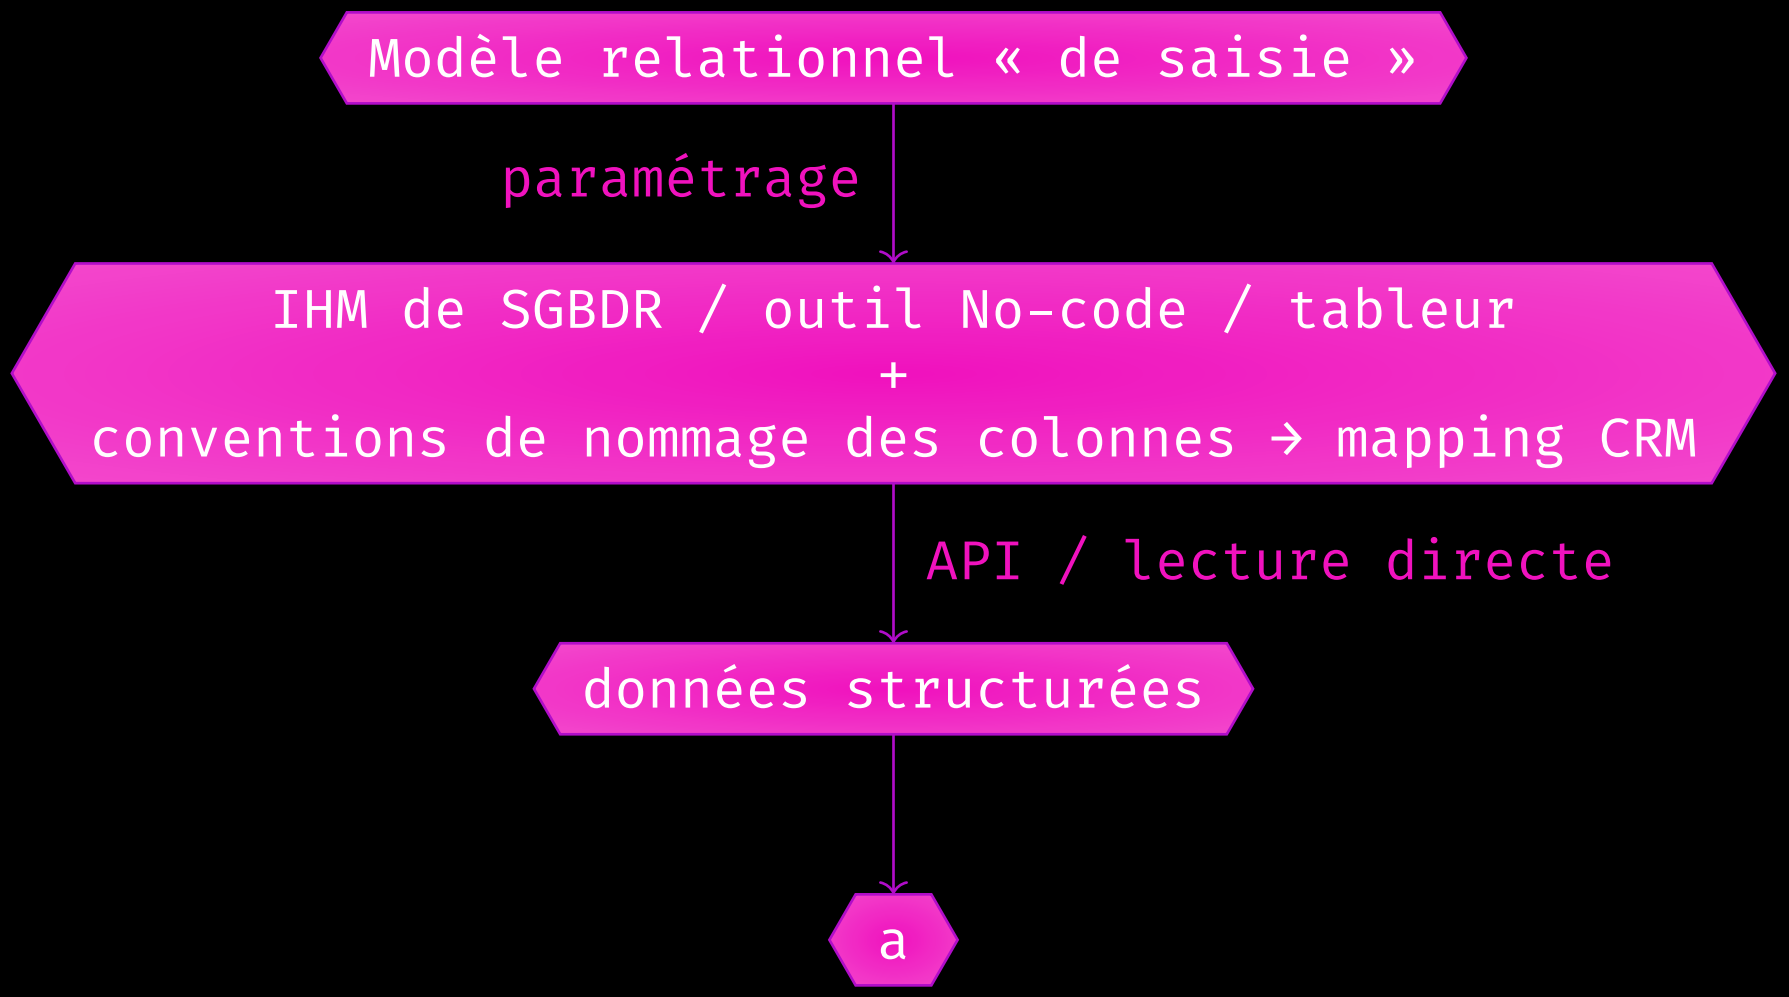

EXPLORER

PÉRENISER