modéliser les données de la recherche avec le CIDOC CRM

📡 thomas.bottini@cnrs.fr

Institut de Recherche en Musicologie UMR 8223

Comment faire tenir les données de la recherche dans le temps ?

📜 Comment s'assurer qu'on puisse toujours les voir, les comprendre et les modifier ?

💾 À quels 🧺 confier ses 🥚 ?

🔮 Comment capter et transmettre les « traditions interprétatives » sans les amoindrir ?

🎓 Comment fonctionner avec des moyens (humains + techniques) limités ?

🌐 Comment favoriser les liens avec d'autres systèmes d'information ?

Comment faire du LOD ⭐⭐⭐⭐⭐ ? → https://5stardata.info/fr/

Essayons d'apporter les moins mauvaises réponses.

ENCODER

MODÉLISER

SAISIR

EXPLORER

PÉRENISER

ENCODER

quelques problèmes potentiels avec les sgbdr

- Un modèle relationnel est souvent conçu ici & maintenant : il formalise et matérialise une tâche d'analyse d'une pratique de recherche spécifique. Le risque est de « réinventer » la roue, sur le plan conceptuel, à chaque réitération de cette démarche d'analyse. Pourtant, il existe des similarités entre les pratiques de recherche en SHS liées aux données numériques.
- La sémantique d'un modèle relationnel ne peut être techniquement partagée, ce qui peut poser des problèmes de lecture et de compréhension plus tard.
- L'accès aux données par un système tiers peut être malaisé. Souvent, on doit développer une API, qui est déterminée par le cahier des charges du projet, alors qu'on sait qu'on ne peut anticiper tous les usages futurs des données (c'est l'idée même des LOD). C'est aussi un point de tension dans le dialogue avec le prestataire : tout changement apporté au modèle vu comme minime par le client peut avoir d'importantes conséquences sur le développement.
- Tout ceci amène à parler d'architectures « en silo ».

pervasivité des sgbdr

- Le panorama technologiques des outils permettant de construire rapidement des applications Web de saisie collaborative de données est dominé par les systèmes reposant sur les SGBDR :
  - CMS & assimilés (Wagtail, Drupal, Omeka, Heurist)
  - systèmes « no-code »
  - frameworks full-stack qui existent dans tous les langages de programmation
- Les SGBDR, et avec eux, la méthode Merise et le SQL, sont enseignés partout, à tous les niveaux. Les compétences d'ingénierie sont donc très répandues.

le web sémantique :

- Promesse d'une base de données à l'échelle du Web. Le Web initial (Tim Berners Lee, 1991) était un Web de documents liés (hypertexte), le Web sémantique est un Web de données liées, chacune étant identifiée par une URL.
- Toute information s'exprime sous la forme d'un triplet sujet/prédicat/objet dans un langage de description qui est le RDF.

- Connectés, ces triplets RDF forment un graphe.
- Chaque prédicat est également identifié par une URL. Cela permet de toujours savoir de quoi on parle quand on dit, par exemple : « Titre ».
- Tout graph RDF est interrogeable en SPARQL (+ standardisé que SQL).
- C'est le milieu technique idéal pour nos préoccupations : LOD, FAIR, etc.

MODÉLISER

une ontologie : quoi, pourquoi ?

- Formalisation d'un modèle conceptuel pour un domaine donné, contenant des classes et des propriétés.
- Utiliser les classes et les propriétés d'une ontologie confère ainsi une sémantique partagée aux données (partage d'individus, partage de prédicats).
- Permet de capitaliser des connaissances de modélisation d'un projet à l'autre.
- Bien des projets de recherche alliant informatique et SHS produisent une ontologie spécifique.
- Le Web sémantique s'accompagne de standards utiles pour nos métiers : SKOS pour les thésaurus, DCMI pour les métadonnées basiques, DOREMUS pour la musique écrite/éditée/jouée/diffusée, LRMOO pour l'information bibliographique, PROV-O pour la provenance de l'information, et bien sûr le CIDOC CRM.

laquelle ? le cidoc crm !

- Ontologie qui documente le patrimoine matériel et immatériel ainsi que les processus de production de connaissances à son propos (sources, connaissances, faits sociaux, concepts, objets matériels, idées dénotées ou connotées, contexte de production des connaissances, etc.).
- Communauté large et établie. Venant du monde des musées, elle est désormais utilisée dans tous les domaines des HN
- Elle est extrêmement abstraite et générique.
- Ontologie centrée événement.
- Informations bibliographiques avec LRMoo (œuvres, expressions, manifestation, item).

hiérarchie des classes du cidoc crm

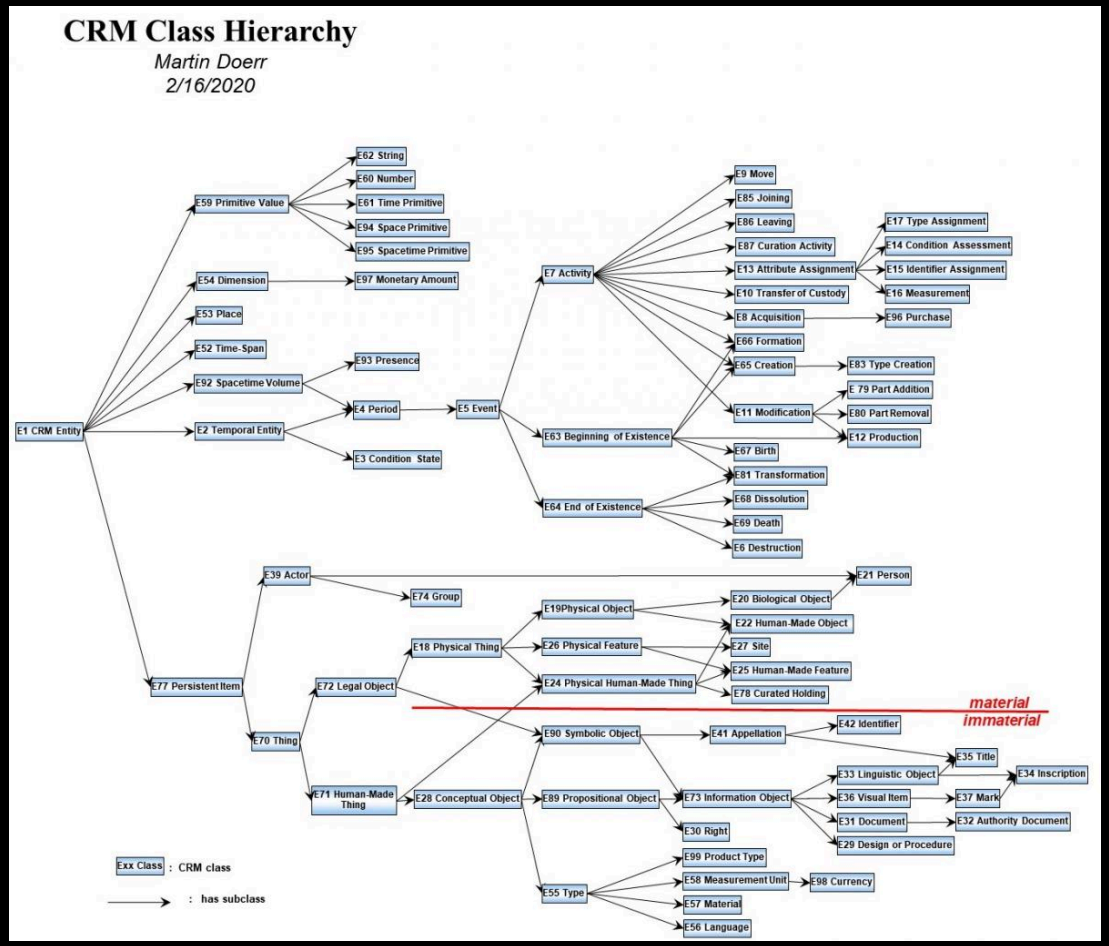

SAISIR

- Les problèmes posés par la structure du CIDOC CRM

EXPLORER

PÉRENISER